



MÜHENDİSLİK VE DOĞA BİLİMLERİ FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ
DERİN ÖĞRENME DERSİ PROJESİ

Pnemunoia Detection Cnn Proje Raporu

Hazırlayan Öğrenciler:

22120205012 Enhar Apuhan

Ders Sorumlusu

İshak DÖLEK

Aralık, 2025

İstanbul Medeniyet Üniversitesi, İstanbul

İÇİNDEKİLER

Sayfa

No:

1. Proje Konusu ve Amacı.....	3
1.1. Problem Tanımı.....	3
1.2. Projenin Amacı ve Önemi.....	3
1.3. Literatür Özeti.....	3
2. Veri Setinin Belirlenmesi.....	4
3. Yöntem ve Algoritma Seçimi.....	4
3.1. Neden Transfer Learning?.....	4
3.2. Model Mimarisi.....	5
4. Model Eğitimi ve Değerlendirilmesi.....	5
4.1. Eğitim Süreci.....	5
4.2. Test Sonuçları ve Metrikler.....	6
5. Sonuç.....	7

1. Proje Konusu ve Amacı

1.1. Problem Tanımı

Zatürre (Pneumonia), akciğerlerdeki hava keseciklerinin iltihaplanması sonucu oluşan ve dünya genelinde, özellikle çocuklar ve yaşlılar için hayati risk taşıyan bir enfeksiyon hastalığıdır. Dünya Sağlık Örgütü verilerine göre, her yıl milyonlarca insan bu hastalıktan etkilenmektedir. Zatürrenin teşhisinde en yaygın yöntem göğüs röntgeni (X-Ray) çekilmesidir. Ancak, X-Ray görüntülerinin uzman radyologlar tarafından incelenmesi zaman alıcıdır ve yorgunluk gibi insani faktörlere bağlı olarak teşhis hataları (yanlış negatif/pozitif) yapılabilmektedir.

1.2. Projenin Amacı ve Önemi

Bu projenin amacı, Derin Öğrenme (Deep Learning) tekniklerini kullanarak X-Ray görüntülerini otomatik analiz eden ve zatürre varlığını yüksek doğrulukla tespit eden bir yapay zeka modeli geliştirmektir. Bu sistem, doktorların yerini almayı değil, onlara hızlı bir "ikinci görüş" sunarak karar destek mekanizması oluşturmayı ve teşhis sürecini hızlandırmayı hedeflemektedir.

1.3. Literatür Özeti

Literatürde tıbbi görüntü işleme alanında Evrişimli Sinir Ağları (CNN) yaygın olarak kullanılmaktadır. Özellikle Transfer Learning (Transfer Öğrenme) yöntemi, sınırlı sayıda tıbbi veriye sahip olunan durumlarda, ImageNet gibi büyük veri setlerinde eğitilmiş (Pre-trained) modellerin (VGG16, ResNet50, InceptionV3) kullanılmasıyla yüksek başarı sağlamaktadır. Bu projede de literatürdeki bu başarılı yaklaşımlar temel alınmıştır.

2. Veri Setinin Belirlenmesi

Projede, Kaggle platformunda açık kaynak olarak sunulan "Chest X-Ray Images (Pneumonia)" veri seti kullanılmıştır.

- Veri Kaynağı: Kaggle - Paul Mooney[1]
- Veri İçeriği: Veri seti, Guangzhou Kadın ve Çocuk Tıp Merkezi'ndeki hastalardan alınan 5,863 adet JPEG formatında X-Ray görüntüsünden oluşmaktadır.
- Sınıf Dağılımı: Veri seti iki ana sınıfa ayrılmıştır:
 - NORMAL: Sağlıklı akciğer görüntüleri.
 - PNEUMONIA: Bakteriyel veya viral zatürre enfeksiyonu içeren görüntüler.
- Veri Ön İşleme (Preprocessing):
 - Tüm görüntüler, kullanılan modelin giriş katmanına uygun olarak 224x224 piksel boyutuna yeniden boyutlandırılmıştır.
 - Piksel değerleri 0-255 aralığından 0-1 aralığına normalize edilmiştir.
 - Veri Çoğaltma (Data Augmentation): Eğitim setindeki dengesizliği yönetmek ve modelin ezberlemesini (overfitting) engellemek için eğitim aşamasında görüntülere rastgele döndürme (rotation), yakınlaştırma (zoom) ve yatay çevirme işlemleri uygulanmıştır.

3. Yöntem ve Algoritma Seçimi

Bu projede Transfer Learning (Transfer Öğrenme) yaklaşımı ve VGG16 mimarisi kullanılmıştır.

3.1. Neden Transfer Learning?

Sıfırdan bir CNN modeli eğitmek çok büyük veri setleri ve yüksek hesaplama gücü gerektirir. Elimizdeki veri seti (~5000 görüntü) derin bir ağı sıfırdan eğitmek için yetersiz kalabileceğinden, VGG16 modelinin ImageNet veri setinde öğrendiği "kenar, doku, şekil" gibi temel özellik çıkarım yeteneklerinden faydalanılmıştır. Bu yöntem hem eğitim süresini kısaltmış hem de modelin genelleme başarısını artırmıştır.

3.2. Model Mimarisi

1. Taban Model (Feature Extractor): VGG16 modelinin evrişimli (convolutional) katmanları alınmış, ağırlıkları dondurulmuştur (frozen). Böylece önceden öğrenilmiş özellikler korunmuştur.
2. Sınıflandırma Katmanı (Classifier - Bizim Eklediğimiz): VGG16'nın üzerine şu katmanlar eklenmiştir:
 - Flatten: 2 boyutlu özellik haritalarını tek boyuta indirger.
 - Dense (512 Nöron, ReLU): Özellikleri yorumlayan tam bağlı katman.
 - Dropout (0.5): Ağın veriyi ezberlemesini önlemek için nöronların rastgele %50'sini kapatır.
 - Dense (1 Nöron, Sigmoid): Çıkış katmanıdır. 0 ile 1 arasında bir değer üreterek "Normal" veya "Zatürre" olasılığını verir.


Kullanılan Teknolojiler: Python 3.11, TensorFlow/Keras, Devenv.

4. Model Eğitimi ve Değerlendirilmesi

4.1. Eğitim Süreci

Model, Binary Crossentropy kayıp fonksiyonu ve Adam optimizasyon algoritması (learning rate: 0.0001) kullanılarak eğitilmiştir. Eğitim sırasında doğrulama (validation) setindeki başarı takip edilmiştir.

Eğitim Grafikleri: Aşağıdaki grafiklerde, eğitim süresince modelin doğruluk (accuracy) ve kayıp (loss) değerlerinin değişimi görülmektedir.




4.2. Test Sonuçları ve Metrikler

Model, eğitimde hiç görmediği Test Veri Seti üzerinde değerlendirilmiştir. Tıbbi teşhislerde sadece doğruluk (accuracy) yeterli değildir; Duyarlılık (Recall) değeri de çok önemlidir çünkü hasta olan bir kişiye "sağlıklı" demek (Yanlış Negatif) hayati risk taşır.

Performans Metrikleri:

- Doğruluk (Accuracy): %0.88
- F1-Skoru: 0.9136
- Recall (Duyarlılık): 0.99 (Pneumonia sınıfı için)

Karmaşıklık Matrisi (Confusion Matrix): Aşağıdaki matris, modelin tahmin performansını detaylı göstermektedir.



Matris incelendiğinde, modelin Zatürre vakalarını tespit etmedeki başarısının yüksek olduğu, sağlıklı ve hasta görüntüleri ayırt edebildiği görülmektedir.

5. Sonuç

Bu projede, derin öğrenme tabanlı Transfer Learning yöntemi kullanılarak akciğer röntgenlerinden zatürre tespiti yapan başarılı bir sistem geliştirilmiştir. Elde edilen F1-Score ve Recall değerleri, modelin medikal bir karar destek sistemi olarak kullanılma potansiyeli taşıdığını göstermektedir.

Gelecek çalışmalarda veri seti genişletilerek ve ResNet50, DenseNet121 gibi daha derin mimariler denenerek başarı oranı daha da artırılabilir

6. Kaynakça

[1] <https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia>